

LAPORAN TEKNIS KOMPREHENSIF

CAPSTONE PROJECT

MindBalance: AI-Powered Anxiety Detection & Mental Wellness Dashboard

ID Tim Capstone Project: CC26-PRU471

Tema Capstone : Healthy Lives & Well-being

Penyusun : Tim Capstone CC26-PRU471

BAB 1. Problem Discovery & Executive Summary

1.1 Latar Belakang Krisis Kesehatan Mental

Kecemasan (anxiety) merupakan salah satu isu kesehatan mental global yang paling krusial dan menuntut perhatian segera, namun dalam realitas sosial sering kali diabaikan atau tidak disadari oleh individu yang mengalaminya hingga mencapai fase klinis yang parah. Banyak orang gagal mengenali bahwa akumulasi dari kebiasaan harian dan faktor gaya hidup mereka—seperti degradasi durasi tidur, konsumsi kafein yang tidak terkontrol, serta eksposur terhadap stres psikologis kronis—secara langsung bertindak sebagai katalisator yang memperburuk kondisi regulasi emosi dan memicu respons kecemasan.

Di Indonesia, pemenuhan kebutuhan akan layanan kesehatan mental menghadapi hambatan sistemik yang masif. Hal ini disebabkan oleh keterbatasan akses geografis maupun finansial terhadap tenaga profesional seperti psikolog dan

psikiater, yang diperparah oleh bertahannya stigma sosial negatif yang melekat kuat di masyarakat. Akibatnya, banyak individu memilih untuk menyembunyikan kondisi mereka, enggan mencari bantuan profesional, dan membiarkan status kesehatan mental mereka memburuk tanpa adanya intervensi dini yang memadai.

1.2 Proyek MindBalance sebagai Solusi Painkiller

Proyek MindBalance diinisiasi secara spesifik sebagai solusi intervensi awal (screening) berbasis data yang bertindak sebagai "painkiller" untuk mengatasi celah penanganan kesehatan mental tersebut. MindBalance mengintegrasikan kapabilitas Data Science dan Artificial Intelligence ke dalam sebuah platform analitik yang mampu memetakan interaksi kompleks antara variabel demografis, kebiasaan hidup, dan indikator fisiologis pengguna. Melalui platform ini, pengguna dapat menginput profil harian mereka secara privat dan aman untuk mendapatkan estimasi tingkat kecemasan awal, sekaligus memperoleh rekomendasi strategi koping (coping strategies) yang dipersonalisasi menggunakan model Generative AI. Penting untuk ditegaskan secara etis bahwa MindBalance diposisikan sebagai alat edukasi dan deteksi awal, bukan sebuah perangkat diagnosis klinis medikal. Platform ini tidak dirancang untuk menggantikan peran diagnosis psikolog atau psikiater, melainkan berfungsi sebagai langkah preventif hulu yang dapat diakses secara instan oleh siapa saja, mengubah kesadaran pasif menjadi tindakan mitigasi yang nyata sebelum kondisi psikologis pengguna berkembang menjadi gangguan klinis yang lebih berat. Keseluruhan esensi proyek ini selaras penuh dengan tujuan pembangunan berkelanjutan (SDGs) dalam pilar *Healthy Lives & Well-being*.

BAB 2. Project Planning & Research Questions

2.1 Research Questions (Pertanyaan Penelitian)

Untuk mengarahkan pengembangan teknis dan metodologi analitik sepanjang

siklus proyek, tim menetapkan empat pertanyaan penelitian utama yang terukur:

1. Faktor gaya hidup dan kebiasaan harian mana yang menunjukkan magnitudo pengaruh dan korelasi paling signifikan terhadap tingkat kecemasan seseorang?
2. Seberapa efektif performa dan efisiensi komputasi dari arsitektur deep learning multi-output yang mengestimasi status klasifikasi sekaligus skor keparahan regresi dalam satu model tunggal, jika dibandingkan dengan implementasi model single-output terpisah?
3. Bagaimana kontribusi penerapan custom loss function dan custom layer kustom yang dibangun dari awal dalam memitigasi dampak class imbalance (ketidakseimbangan kelas) yang ekstrem pada target dataset kecemasan?
4. Apakah pemanfaatan Generative AI dalam menghasilkan rekomendasi koping memberikan keluaran yang lebih relevan, kontekstual, dan empatik bagi pengguna dibandingkan pendekatan rekomendasi statis berbasis aturan (rule-based)?

2.2 Matriks Penugasan Anggota Tim (Job Desk)

Pekerjaan didistribusikan secara terstruktur berdasarkan spesialisasi alur belajar (learning path) untuk memastikan efisiensi kolaborasi tanpa hambatan blocking:

Nama Anggota / ID	Role / Learning Path	Tanggung Jawab Utama (Job Desk)
Vincentius Tanujaya (CACC244D6Y2546)	Artificial Intelligence Engineer	Merancang dan mengimplementasikan arsitektur deep learning multi-output TensorFlow Functional API; membangun komponen

Nama Anggota / ID	Role / Learning Path	Tanggung Jawab Utama (Job Desk)
		kustom (FeatureInteractionBlock, WeightedCombinedLoss, AnxietyTrainingMonitor); mengembangkan custom training loop dengan tf.GradientTape; mengonfigurasi REST API mandiri dengan FastAPI dan mengintegrasikan Google Gemini API SDK.
Caroline Cristine Sirait (CDCC200D6X2537)	Data Scientist	Melakukan data wrangling secara end-to-end (gathering, assessing, manual cleaning); menyusun Data Dictionary; melaksanakan Exploratory Data Analysis (EDA) mendalam beserta visualisasinya; melakukan rekayasa fitur (feature engineering) untuk membentuk indeks komposit.
Nabillah Indah Tsuraya	Data Scientist	Mengembangkan dan

Nama Anggota / ID	Role / Learning Path	Tanggung Jawab Utama (Job Desk)
(CDCC488D6X2661)		menyusun visualisasi interaktif pada dashboard Streamlit; melakukan deployment dashboard ke Streamlit Community Cloud; melaksanakan skenario pengujian fungsionalitas visual; menyusun dokumen Technical Report komprehensif.

2.3 Sumber Daya Proyek dan Tech Stack

Arsitektur teknologi MindBalance dibangun menggunakan kombinasi perangkat lunak open-source dan komersial terkemuka untuk memastikan aspek skalabilitas dan reliabilitas:

- **Bahasa Pemrograman:** Python 3.12 (menjamin kompatibilitas penuh terhadap TensorFlow di ekosistem cloud).
- **Framework Deep Learning:** TensorFlow 2.15.0 (digunakan untuk pemodelan Functional API, pembuatan komponen kustom, dan ekspor ke format .keras).
- **Backend REST API:** FastAPI + Uvicorn (menyediakan layanan inferensi model yang ringan, asinkron, dan tervalidasi via Pydantic).
- **Recommendation Engine:** Google Gemini API (gemini-1.5-flash) untuk menghasilkan narasi coping strategy yang empatik.

- **Manipulasi & Analisis Data:** Pandas, NumPy, Scikit-Learn, dan Imbalanced-Learn.
- **Visualisasi & Dashboard:** Matplotlib, Seaborn, Plotly, dan Dashboard Interaktif berbasis Streamlit Cloud.
- **Monitoring & Version Control:** TensorBoard untuk visualisasi metrik pelatihan, serta Git & GitHub untuk kolaborasi repositori.

BAB 3. Data Understanding, Preparation, & Data Dictionary

3.1 Karakteristik Dataset

Proyek MindBalance mengeksplorasi dataset `enhanced_anxiety_dataset.csv` (diekstrak menjadi file produksi `cleaned_anxiety_data.csv`) yang merepresentasikan data survei mandiri (self-reported survey data) terstruktur sebanyak 11.000 observasi. Dataset awal memiliki 19 fitur (18 fitur input numerik dan kategorikal, serta 1 fitur target kontinu berupa skor kecemasan) sebelum dilakukan rekayasa fitur lanjutan. Ukuran memori dataset ini sangat efisien sebesar 4977.7 KB. Target variabel asli adalah Anxiety Level (1-10) bertipe float yang kemudian dikonversi menjadi integer domain rentang 1 hingga 10.

3.2 Proses Data Wrangling

Untuk menjamin keandalan data sebelum masuk ke tahap pemodelan dan menghindari kebocoran data (data leakage), alur data wrangling diimplementasikan secara ketat:

1. **Gathering Data:** Mengimpor berkas mentah `enhanced_anxiety_dataset.csv` ke dalam lingkungan Google Colab.
2. **Assessing Data:** Melakukan pengecekan kualitas data secara komparatif

menggunakan fungsi terprogram. Hasil penilaian membuktikan secara absolut bahwa tidak terdapat missing values (0 data kosong) dan tidak terdeteksi adanya data duplikat (0 baris duplikasi). Nilai kardinalitas fitur kategorikal diperiksa dan dipastikan konsisten tanpa variasi penulisan karakter kapital yang salah.

3. **Cleaning Data & Validation:** Nama kolom dibersihkan dari spasi liar (strip whitespace). Dilakukan validasi domain numerik menggunakan fungsi kustom untuk memastikan seluruh nilai berada dalam batas fisis medis yang rasional. Dilakukan penambahan fitur target klasifikasi ordinal bernama *Anxiety_Category* yang memetakan skor kontinu ke dalam tiga klaster: *Low* (Skor ≤ 3), *Medium* (Skor 4-6), dan *High* (Skor 7-10). Distribusi kelas target klasifikasi adalah 5.202 records untuk Low (47.3%), 4.661 records untuk Medium (42.4%), dan 1.137 records untuk High (10.3%). Ketidakseimbangan kelas ini diidentifikasi sebagai risiko bias prediksi yang ditangani pada fase training.

3.3 Tabel Data Dictionary Komprehensif (23 Fitur)

Nama Fitur	Tipe Data	Rentang / Domain	Deskripsi Fungsional
Age	Numeric (int)	18 - 64	Usia responden dalam satuan tahun.
Gender	Categorical	Male, Female, Other	Identitas jenis kelamin responden.
Occupation	Categorical	13 Pilihan Pekerjaan	Profesi utama atau pekerjaan harian

Nama Fitur	Tipe Data	Rentang / Domain	Deskripsi Fungsional
			responden.
Sleep Hours	Numeric (float)	2.3 - 11.3	Rata-rata durasi tidur per malam dalam satuan jam.
Physical Activity (hrs/week)	Numeric (float)	0.0 - 10.1	Durasi aktivitas fisik/olahraga per minggu dalam jam.
Caffeine Intake (mg/day)	Numeric (int)	0 - 599	Rata-rata konsumsi kafein harian dalam miligram.
Alcohol Consumption (drinks/week)	Numeric (int)	0 - 19	Jumlah konsumsi minuman beralkohol per minggu.
Smoking	Binary	Yes, No	Status apakah responden merokok secara aktif.
Family History of Anxiety	Binary	Yes, No	Riwayat gangguan kecemasan klinis pada keluarga inti.
Stress Level (1-10)	Ordinal (int)	1 - 10	Tingkat stres umum subjektif

Nama Fitur	Tipe Data	Rentang / Domain	Deskripsi Fungsional
			berbasis skala Likert 1-10.
Heart Rate (bpm)	Numeric (int)	60 - 119	Detak jantung istirahat (resting heart rate) dalam BPM.
Breathing Rate (breaths/min)	Numeric (int)	12 - 29	Frekuensi napas istirahat per menit.
Sweating Level (1-5)	Ordinal (int)	1 - 5	Tingkat keparahan keringat berlebih subjektif skala 1-5.
Dizziness	Binary	Yes, No	Status apakah responden sering mengalami pusing.
Medication	Binary	Yes, No	Apakah sedang mengonsumsi obat terkait kecemasan.
Therapy Sessions (per month)	Numeric (int)	0 - 12	Jumlah sesi konseling/terapi psikologis per bulan.
Recent Major Life Event	Binary	Yes, No	Apakah mengalami trauma/kejadian

Nama Fitur	Tipe Data	Rentang / Domain	Deskripsi Fungsional
			besar dalam 6 bulan terakhir.
Diet Quality (1-10)	Ordinal (int)	1 - 10	Kualitas pola makan harian subjektif skala 1-10.
Anxiety Level (1-10)	Numeric (int)	1 - 10	Skor keparahan kecemasan asli (Target Regresi).
Anxiety_Category	Categorical (Ordinal)	Low, Medium, High	Kategori kecemasan turunan (Target Klasifikasi).
SleepEfficiencyScore	Numeric (float)	0.0 - 1.0	Fitur Rekayasa: Kombinasi durasi tidur dan kafein.
LifestyleRiskIndex	Numeric (float)	0.0 - 1.0	Fitur Rekayasa: Indeks komposit risiko perilaku harian.
AnxietyCompositeScore	Numeric (float)	0.0 - 1.0	Fitur Rekayasa: Indeks gabungan sinyal fisik dan

Nama Fitur	Tipe Data	Rentang / Domain	Deskripsi Fungsional
			mental.

BAB 4. Exploratory Data Analysis (EDA) & Business Insights

4.1 Analisis Univariat

Berdasarkan analisis univariat, target Anxiety Level menunjukkan distribusi yang condong ke kanan (right-skewed), di mana konsentrasi data terbesar menumpuk pada tingkat keparahan rendah hingga sedang, sementara kategori kecemasan ekstrim tinggi (High) menempati proporsi minoritas sebesar 10.3%. Pada fitur numerik gaya hidup, Sleep Hours berdistribusi normal di sekitar rata-rata 6.65 jam, sedangkan Caffeine Intake memperlihatkan sebaran yang relatif seragam di seluruh rentang nilai. Untuk fitur kategorikal, proporsi gender dalam dataset sangat berimbang (Female, Male, Other), begitu pula sebaran biner pada status merokok dan riwayat medis keluarga.

4.2 Analisis Korelasi Linear Pearson

Ekstraksi koefisien korelasi Pearson terhadap target numerik memberikan temuan kunci mengenai faktor pendorong utama (drivers) dan faktor pelindung (protective factors) kecemasan:

- **Top 5 Positive Correlations:** Stress Level (1-10) memimpin secara dominan dengan koefisien (+0.6679), diikuti oleh Therapy Sessions (per month) (+0.5176), Caffeine Intake (mg/day) (+0.3507), Heart Rate (bpm) (+0.1889), dan

Sweating Level (1-5) (+0.1601).

- **Top 5 Negative Correlations:** Sleep Hours menunjukkan efek protektif terkuat (-0.4938), diikuti oleh Physical Activity (hrs/week) (-0.2432), Diet Quality (1-10) (-0.2202), dan Age (-0.0743). Hubungan linear untuk Alcohol Consumption tercatat sangat lemah mendekati nol (-0.1006).

4.3 Solusi terhadap Pertanyaan Bisnis (Business Questions)

Melalui visualisasi bivariat dan multivariat, lima pertanyaan bisnis utama proyek ini berhasil dijawab:

1. **Faktor Dominan (BQ1):** Sinyal stres subjektif serta durasi tidur harian secara linear merupakan faktor paling berpengaruh yang mengendalikan fluktuasi tingkat kecemasan.
2. **Distribusi Demografis (BQ2):** Sebaran kategori kecemasan antar kelompok gender cenderung seragam (Proporsi High Anxiety berada di kisaran 10.5% untuk Wanita, 10.7% untuk Pria, dan 9.8% untuk Gender Lainnya). Namun, berdasarkan profesi, kelompok pekerjaan dengan tingkat tekanan kognitif tinggi seperti *Lawyer* (Rata-rata skor 4.21) dan *Doctor* (4.20) mencatatkan rerata skor kecemasan tertinggi dibandingkan profesi lainnya.
3. **Sinyal Fisiologis (BQ3):** Sinyal somatik tubuh meningkat secara monoton seiring meningkatnya keparahan kecemasan. Kelompok High Anxiety memiliki rata-rata resting heart rate sebesar 102.77 BPM (dibandingkan Low/Medium di angka 89.55 BPM), frekuensi pernapasan melonjak ke 24.00 napas per menit, dan tingkat ekskresi keringat (sweating level) mencapai rata-rata skala 3.87.
4. **Interaksi Tidur & Kafein (BQ4):** Terbukti adanya efek multiplikasi (compounding interaction). Pengguna yang mengombinasikan durasi tidur sangat rendah (Sleep Risk: Low) dengan konsumsi kafein ekstrem (Caffeine Risk: High) melambungkan rata-rata skor kecemasan mereka ke angka tertinggi, yaitu 8.25 dari 10.

5. **Interaksi Riwayat Keluarga (BQ5):** Responden yang mewarisi riwayat kecemasan dalam keluarga (Family History: Yes) secara konsisten menunjukkan baseline skor kecemasan yang lebih tinggi (rata-rata 4.31) dibandingkan kelompok tanpa riwayat keluarga (3.50), serta memperlihatkan kerentanan fisik yang lebih sensitif terhadap stresor eksternal.

BAB 5. Feature Engineering

Untuk meningkatkan kerapatan sinyal data (signal density) sebelum diekstraksi oleh lapisan neural network, dibentuk tiga fitur komposit berbasis pengetahuan domain medis dasar (domain-informed features):

1. **Sleep Efficiency Score (SES):**

Formulasi ini mengukur efisiensi pemulihan biologis bersih dengan menormalkan durasi tidur dan mengurangi pengaruh destruktif dari konsumsi stimulan kafein di malam hari.

$$\text{Sleep_Norm} = (\text{Sleep_Hours} - \text{Min_Sleep}) / (\text{Max_Sleep} - \text{Min_Sleep})$$

$$\text{Caffeine_Norm} = (\text{Caffeine_Intake} - \text{Min_Caf}) / (\text{Max_Caf} - \text{Min_Caf})$$

$$\text{SES} = (\text{Sleep_Norm} * 0.7) + ((1.0 - \text{Caffeine_Norm}) * 0.3)$$

Skor berkisar antara 0-1; nilai tinggi merepresentasikan efisiensi tidur yang optimal. Fitur ini terbukti memiliki korelasi negatif kuat (-0.552) terhadap tingkat kecemasan.

2. **Lifestyle Risk Index (LRI):**

Indeks ini merangkum total beban risiko perilaku harian pengguna melalui penjumlahan berbobot (weighted sum) dari variabel stres psikologis, status merokok, alkoholisme, riwayat keturunan, kejadian trauma, serta inversi dari

aktivitas fisik dan kualitas makanan.

$$\begin{aligned} \text{LRI} = & (\text{Stress_Norm} * 0.25) + (\text{Smoking_Enc} * 0.10) + \\ & (\text{Alcohol_Norm} * 0.10) + \\ & (\text{FamilyHistory_Enc} * 0.15) + (\text{LifeEvent_Enc} * 0.15) + \\ & ((1.0 - \text{Activity_Norm}) * 0.10) + ((1.0 - \text{Diet_Norm}) * \\ & 0.15) \end{aligned}$$

Semakin tinggi LRI mendekati 1.0, semakin besar paparan perilaku berisiko pengguna. LRI berkorelasi positif kuat (+0.573) dengan varians target kecemasan.

3. **Anxiety Composite Score (ACS):**

ACS bertindak sebagai proksi auxiliary pra-model yang menyatukan indikator psikologis subjektif (stres) dengan manifestasi objektif dari sistem saraf otonom (detak jantung, laju napas, keringat) dan faktor risiko genetik.

$$\begin{aligned} \text{ACS} = & (\text{Stress_Norm} * 0.30) + (\text{HeartRate_Norm} * 0.20) + \\ & (\text{BreathingRate_Norm} * 0.20) + \\ & (\text{Sweating_Norm} * 0.15) + (\text{FamilyHistory_Enc} * 0.15) \end{aligned}$$

ACS menunjukkan performa korelasi linear tertinggi terhadap target esensial, yakni sebesar (+0.621).

BAB 6. Model Development & Custom TensorFlow Components

6.1 Arsitektur Model Multi-Output

Model dikembangkan menggunakan TensorFlow Functional API dengan pendekatan arsitektur Multi-Output Deep Learning. Desain ini memanfaatkan satu tulang punggung (shared backbone) jaringan saraf tiruan dalam yang mempelajari

representasi fitur bersama, yang kemudian bercabang menjadi dua sub-jaringan untuk menyelesaikan dua tugas komplementer sekaligus:

- **Output Klasifikasi (class_output):** Lapisan Dense dengan fungsi aktivasi Softmax untuk menghasilkan probabilitas multi-kelas terhadap 3 kategori kecemasan (Low, Medium, High).
- **Output Regresi (reg_reshape):** Lapisan Dense dengan fungsi aktivasi Sigmoid untuk memprediksi nilai kontinu tingkat kecemasan yang telah dinormalisasi ke skala 0-1, yang kemudian dikembalikan ke skala asli 1-10 pada tahap inferensi.

Input model berdimensi 21 fitur, yang mencakup 18 fitur orisinal ditambah 3 fitur hasil rekayasa komposit. Total parameter model sangat efisien sebesar 14.180 parameter (13.732 trainable dan 448 non-trainable). Data dibagi secara terlapis (stratified split) dengan proporsi 70% Pelatihan, 15% Validasi, dan 15% Pengujian. Preprocessing menerapkan RobustScaler untuk menormalisasi fitur numerik agar tangguh terhadap pencilan data.

6.2 Implementasi Komponen Kustom TensorFlow

Untuk mengamankan performa tinggi dan mengatasi karakteristik data yang menantang, diimplementasikan tiga komponen kustom berbasis kode Python tingkat rendah:

1. Custom Layer: FeatureInteractionBlock

Lapisan ini mengadopsi mekanisme atensi mandiri terproyeksi (self-attention-style mechanism) untuk secara dinamis mempelajari hubungan berpasangan (pairwise interactions) antar variabel laten, memperkuat sinyal penting, dan mempertahankan sisa informasi melalui koneksi residual dan Layer Normalization.

```
class FeatureInteractionBlock(layers.Layer):  
    def __init__(self, units, dropout_rate=0.3, **kwargs):  
        super().__init__(**kwargs)  
        self.units = units
```

```

self.dropout_rate = dropout_rate
self.dense1 = layers.Dense(units * 2, activation="gelu")
self.dense2 = layers.Dense(units)
self.proj = layers.Dense(units, use_bias=False)
self.norm = layers.LayerNormalization()
self.dropout = layers.Dropout(dropout_rate)

def call(self, inputs, training=False):
    residual = self.proj(inputs)
    x = self.dense1(inputs)
    x = self.dropout(x, training=training)
    x = self.dense2(x)
    return self.norm(x + residual)

def get_config(self):
    config = super().get_config()
    config.update({"units": self.units, "dropout_rate":
self.dropout_rate})
    return config

```

2. Custom Loss: WeightedCombinedLoss

Fungsi kerugian kustom ini menyatukan optimalisasi klasifikasi dan regresi secara simultan. Untuk klasifikasi, diimplementasikan Focal Loss dengan pembobotan kelas penyeimbang (class-aware weights) guna memaksa model berfokus pada sampel minoritas kelas High yang sulit dipelajari. Untuk regresi, digunakan Huber Loss yang kebal terhadap pencilan ekstrem. Kedua komponen loss digabungkan secara linier dikendalikan oleh hiperparameter alpha.

```

class WeightedCombinedLoss(tf.keras.losses.Loss):
    def __init__(self, class_weights, alpha=0.7, gamma=2.0,

```



```

delta=0.8, **kwargs):
    super().__init__(**kwargs)
    self.class_weights = tf.constant(class_weights,
dtype=tf.float32)
    self.alpha = alpha
    self.gamma = gamma
    self.delta = delta

    def call(self, y_true, y_pred):
        y_class_true = tf.cast(y_true[:, 0], tf.int32)
        y_reg_true = y_true[:, 1]
        y_class_pred = tf.clip_by_value(y_pred[:, :3],
tf.keras.backend.epsilon(), 1.0 - tf.keras.backend.epsilon())
        y_reg_pred = y_pred[:, 3]

        y_class_true_onehot = tf.one_hot(y_class_true, depth=3)
        p_t = tf.reduce_sum(y_class_true_onehot * y_class_pred,
axis=-1)
        p_t = tf.clip_by_value(p_t, tf.keras.backend.epsilon(),
1.0 - tf.keras.backend.epsilon())

        alpha_t = tf.gather(self.class_weights, y_class_true)
        ce_per_sample =
tf.keras.losses.categorical_crossentropy(y_class_true_onehot,
y_class_pred)
        focal_loss = tf.reduce_mean(alpha_t * tf.pow(1.0 - p_t,
self.gamma) * ce_per_sample)

        abs_err = tf.abs(y_reg_true - y_reg_pred)

```

```

        huber_loss = tf.reduce_mean(tf.where(abs_err <=
self.delta, 0.5 * tf.square(abs_err), self.delta * (abs_err -
0.5 * self.delta)))

    return self.alpha * focal_loss + (1.0 - self.alpha) *
huber_loss

```

3. Custom Callback: AnxietyTrainingMonitor

Callback kustom ini bertugas melacak metrik performa di setiap akhir epoch, memantau celah generalisasi (generalization gap) antara loss training dan validasi untuk mendeteksi risiko overfitting secara dini, serta secara otomatis mengeksport seluruh riwayat pelatihan ke berkas eksternal JSON.

```

class AnxietyTrainingMonitor(Callback):
    def __init__(self, patience_overfit=5, verbose=True):
        super().__init__()
        self.patience_overfit = patience_overfit
        self.verbose = verbose
        self.history_log = []
        self.best_val_loss = np.inf
        self.overfit_counter = 0

    def on_epoch_end(self, epoch, logs=None):
        logs = logs or {}
        train_loss = logs.get("loss", 0)
        val_loss = logs.get("val_loss", 0)
        self.history_log.append({"epoch": epoch + 1, **logs})

        if val_loss < self.best_val_loss:
            self.best_val_loss = val_loss

```

```

        self.overfit_counter = 0
    else:
        self.overfit_counter += 1

    gap = train_loss - val_loss
    overfitting = gap > 0.1
    if self.verbose and (epoch + 1) % 5 == 0:
        status = "OVERFIT_RISK" if overfitting else "OK"
        print(f"[Monitor] Epoch {epoch+1:03d} |
train_loss={train_loss:.4f} | val_loss={val_loss:.4f} |
Status={status}")

    def on_train_end(self, logs=None):
        with open("training_history.json", "w") as f:
            json.dump(self.history_log, f, indent=2)
            print(f"[Monitor] Training complete. Best val_loss:
{self.best_val_loss:.4f}")

```

BAB 7. Advanced Training Phase

7.1 Custom Training Loop dengan tf.GradientTape

Pada fase pelatihan tingkat lanjut, tim mengimplementasikan alur pelatihan kustom (custom training loop) secara penuh dari awal mengeksplorasi fungsi dekorator grafis `@tf.function` dan objek konteks `tf.GradientTape`. Pendekatan ini menggantikan eksekusi standar `model.fit()` guna memberikan kendali mutlak kepada AI Engineer atas komputasi propagasi maju, kalkulasi gradien, pemotongan gradien secara global (global norm gradient clipping) pada ambang batas nilai 2.0 untuk meredam ledakan gradien (exploding gradients), serta pembaruan matriks

bobot parameter secara manual pada optimizer Adam.

Data pelatihan diumpankan dalam format objek performa tinggi `tf.data.Dataset`, melalui proses pengocokan acak (shuffling) dengan ukuran penyangga (buffer size) sebesar 4.096 sampel dan diproses dalam kelompok (batch size) sebesar 256 sampel per iterasi dengan fitur prefetching asinkron untuk mengeliminasi bottleneck memori I/O. Pelatihan dibatasi oleh mekanisme Early Stopping dengan toleransi kesabaran (patience) sebesar 7 epoch berturut-turut tanpa adanya reduksi nilai kerugian validasi, memastikan model yang diekspor merupakan konfigurasi parameter yang paling optimal.

7.2 Monitoring melalui Terintegrasi TensorBoard Log

Seluruh grafik metrik evaluasi dari objek fungsi loss kustom, nilai akurasi klasifikasi, hingga Mean Absolute Error regresi dicatat secara real-time pada setiap langkah iterasi ke dalam folder direktori penyimpanan log biner internal `tb_logs/mindbalance_gradtape/`. Berkas log TensorBoard ini disertakan secara utuh ke dalam repositori submission final untuk memvalidasi proses pelatihan yang transparan dan akuntabel.

BAB 8. Model Evaluation & Performance Analysis

8.1 Hasil Evaluasi Akhir pada Held-Out Test Set

Model dievaluasi secara ketat menggunakan data pengujian eksternal terpisah (held-out test set) sebesar 15% dari total keseluruhan populasi dataset asli, yang bersifat murni terisolasi dan tidak pernah dilihat oleh model selama fase pelatihan maupun validasi. Hasil ekstraksi metrik performa dicatat sebagai berikut:

- **Akurasi Klasifikasi Akhir:** Terwujud skor akurasi sebesar **77.82%**. Meskipun capaian ini menunjukkan kinerja klasifikasi yang kuat dan generalisasi yang sangat stabil (bebas overfitting), nilai ini berada sedikit di bawah target ideal

rencana awal proyek sebesar $\geq 85\%$. Ketidakseimbangan data awal (class imbalance) diidentifikasi sebagai faktor pembatas utama keakuratan klasifikasi fungsional. Nilai **F1-Score (Weighted Average)** tercatat kokoh di angka **0.7790**.

- **Metrik Kinerja Regresi Kontinu:** Evaluasi terhadap prediksi skor keparahan kontinu mencatatkan nilai **Mean Absolute Error (MAE)** sebesar **0.8706** pada skala mentah asli 1-10. Jika ditransformasikan kembali ke dalam format normalisasi skala indeks 0-1, nilai MAE setara dengan **0.0967**, yang berada sedikit di atas ambang batas target ideal awal ($MAE \leq 0.02$). Nilai Root Mean Squared Error (RMSE) berada di angka 1.0999, dan koefisien determinasi **R-Squared (R^2)** mencatatkan angka **0.7289**, mengonfirmasi bahwa arsitektur model mampu menjelaskan sebesar 72.89% variabilitas dari fenomena kecemasan dalam dataset.

8.2 Interpretasi Klasifikasi dan Confusion Matrix

Berdasarkan laporan klasifikasi per kelas target, model menunjukkan performa presisi yang sangat tinggi pada klaster kelas mayoritas Low dengan nilai precision (+0.97) dan recall (+0.89), menghasilkan total 604 sampel terprediksi secara benar. Pada klaster kelas kritis High, penanganan bobot kelas pada loss function kustom berhasil mengamankan nilai precision sebesar (+0.73) dan recall sebesar (+0.75), dengan total 533 sampel terklasifikasi secara akurat dari total populasi pengujian. Kesalahan klasifikasi terbesar menumpuk pada area batas ambang antara kelas Medium dan High, yang dinilai wajar karena ambang klasifikasi ordinal bersifat kontinu.

BAB 9. Deployment Architecture & System Integration

9.1 Desain Arsitektur Sistem Hulu-ke-Hilir

MindBalance diimplementasikan secara terintegrasi melalui tiga lapisan sistem penanganan data yang beroperasi secara sinkron:

1. **Lapisan Antarmuka Pengguna (Inference UI - Streamlit Cloud):** Berperan sebagai frontend dashboard interaktif yang melayani navigasi multi-halaman (Executive Overview, Dataset Overview, Lifestyle Insights, Physical Indicators, Correlation Explorer, dan AI Detection Form). Lapisan ini menerima input dari pengguna melalui form kendali grafis, mengonversi data string kategorikal (Gender, Occupation) menjadi angka representasi, serta menghitung nilai rekayasa fitur indeks SES, LRI, dan ACS secara internal.
2. **Lapisan Backend (REST API FastAPI):** Bertindak sebagai pelayan produksi yang memuat model deep learning biner utama format mindbalance_model_new.keras beserta pustaka normalisasi data RobustScaler (scaler.pkl) ke dalam memori server. Skenario Fallback Rule-Based diaktifkan secara otomatis jika terjadi kegagalan pemuatan model biner.
3. **Lapisan Recommendation Engine (Google Gemini API):** Memanfaatkan model gemini-1.5-flash. Setelah model klasifikasi-regresi menghasilkan nilai prediksi kecemasan, backend menyusun sebuah prompt teks terenkapsulasi yang mengirimkan skor analitik beserta profil gaya hidup pengguna secara teranonimisasi total (anonymized lifestyle profile) tanpa menyertakan data pribadi sensitif (PII). Gemini API memproses prompt tersebut untuk memproduksi narasi intervensi coping harian yang personal, empatik, serta praktis dalam Bahasa Indonesia di bawah batasan panjang 150 kata. Skenario teks rekomendasi statis lokal disediakan sebagai fallback otomatis jika kuota API pihak ketiga habis.

BAB 10. Ethics, Limitations, & Conclusion

10.1 Batasan Produk dan Etika Privasi

Secara etis, MindBalance menerapkan kebijakan privasi data yang ketat. Platform tidak mengumpulkan, meminta, atau menyimpan informasi identitas pribadi (seperti nama, nomor kontak, atau rekam medis). Seluruh input yang dimasukkan ke dalam form deteksi AI hanya diproses secara temporer di dalam memori sesi aplikasi (app session memory) untuk keperluan inferensi langsung dan segera dihancurkan setelah sesi ditutup. Platform mencantumkan peringatan keselamatan medis (medical warning) di setiap halaman inferensi, menegaskan batasan mutlak bahwa produk ini merupakan alat skrining edukatif awal dan bukan pengganti diagnosis medis klinis.

10.2 Kesimpulan dan Keselarasan Capaian

Laporan ini menyimpulkan bahwa proyek capstone MindBalance (CC26-PRU471) telah berhasil diselesaikan dengan sukses dari tahap penemuan masalah hingga perwujudan produk fungsional siap pakai yang dideploy secara publik di Streamlit Cloud. Meskipun terdapat beberapa penyesuaian ruang lingkup (scope adjustments) jika dikomparasikan terhadap dokumen perencanaan awal (Project Plan)—seperti performa akurasi final model (77.82%) yang berada sedikit di bawah ambang target ideal ($\geq 85\%$) akibat class imbalance, serta penyatuan fungsionalitas FastAPI ke dalam satu kesatuan dashboard Streamlit terpadu demi efisiensi latensi—fitur utama dan esensi nilai kegunaan produk (core value proposition) sebagai intervensi dini kesehatan mental berbasis AI berhasil dipertahankan secara utuh dan terbukti beroperasi secara stabil.